Введение.

В рамках проекта был проведён RFM-анализ клиентской базы аптечной сети с целью сегментации клиентов и выявления поведенческих различий между группами. Клиенты были сегментированы на основе давности последней покупки, частоты покупок и суммарной выручки. Результаты анализа визуализированы в интерактивном дашборде, что позволяет оценить вклад сегментов в выручку и определить приоритетные направления маркетинговых коммуникаций.

Цель исследования:

Построить RFM-сегментацию клиентов аптечной сети и определить ключевые клиентские группы с точки зрения ценности и риска оттока.

Задачи

В рамках исследования были поставлены следующие задачи:

- подготовить витрину данных на уровне клиента;
- рассчитать RFM-метрики;
- определить пороговые значения для RFM – оценок;
- сформировать клиентские сегменты на основе RFM-метрик;
- визуализировать результаты в дашборде.

Методология и ход рассуждений.

В качестве основы для сегментации были использованы три классические метрики RFM-анализа:

- *Recency* – количество дней с момента последней покупки клиента;
- *Frequency* – количество покупок клиента за рассматриваемый период;
- *Monetary* – суммарная выручка, принесённая клиентом.

Данные показатели широко применяются в розничной торговле, поскольку позволяют комплексно оценить клиентское поведение: текущую активность клиента, интенсивность взаимодействия с компанией и его экономическую ценность для бизнеса. В контексте аптечной сети данные метрики особенно релевантны, поскольку покупки носят повторяющийся характер, а удержание клиентов является важным фактором стабильности выручки.

Пороговые значения для RFM-оценок определялись на основе анализа распределений данных, медианных значений и квартильных перцентилей. Такой подход позволяет минимизировать субъективность при сегментации клиентов и основывать классификацию исключительно на фактических данных.

Основные гипотезы исследования:

- небольшая доля клиентов с высокой частотой и суммой покупок формирует значительную часть общей выручки
- клиенты с давней последней покупкой и низкой частотой обладают повышенным риском оттока
- сегменты со средней активностью имеют потенциал роста при корректных маркетинговых воздействиях.

Ход рассуждений.

Логика анализа строилась от общего к частному: сначала была изучена структура клиентской базы и распределение клиентов по сегментам, затем – вклад каждого сегмента в выручку и различия в поведенческих метриках. Такой подход позволил не только сегментировать клиентов, но и сформировать основу для дальнейших управленческих и маркетинговых решений.

Содержательная часть.

Любой анализ клиентской базы нуждается в идентификаторе пользователя, позволяющий связать покупки одного пользователя во времени. В таблице *sales* идентификатор клиента отсутствует, поэтому для анализа была выбрана таблица *bonuscheques*, где в качестве идентификатора клиента используется поле *card* – номер карты лояльности

Запрос 1. Проверка дубликатов чеков.

Перед расчетом RFM-метрик необходимо проверить наличие дубликатов чеков, поскольку повторяющиеся значения *doc_id* могут искажать показатели *Frequency* и *Monetary*.

```
select
  doc_id,
  count(*) as cnt
from bonuscheques
group by doc_id
having count(*) > 1
```

Результаты запроса показали наличие чеков с повторяющимся *doc_id*. Это означает, что в исходных данных один и тот же чек может быть представлен несколькими строками. Для корректного расчёта RFM-метрик необходимо выполнить дедупликацию и привести данные к формату «одна строка – один чек – один клиент».

В ходе проверки данных также был обнаружен единичный случай, когда один *doc_id* связан с несколькими бонусными картами. Поскольку доля таких наблюдений пренебрежимо мала относительно общего количества чеков, было принято решение не усложнять логику обработки данных. В дальнейшем чек агрегируется стандартным образом.

Запрос 2. Дедупликация данных

Для корректного расчёта RFM-метрик необходимо выполнить дедупликацию чеков и привести данные к формату «одна строка – один чек – один клиент».

```
with checks as (
    select
        doc_id,
        card as customer_id,
        min(datetime) as dt,
        max(summ_with_disc) as amount
    from bonuscheques
    group by doc_id, card
)
select *
from checks
```

В данном запросе формируется агрегированная таблица чеков:

- *doc_id* – идентификатор чека
- *card* – выступает как идентификатор клиента
- *min(datetime)* – дата покупки
- *max(summ_with_disc)* – итоговая сумма чека. Для расчёта метрики *Monetary* используется поле *summ_with_disc*, поскольку оно отражает фактическую сумму покупки с учётом применённых скидок и списания бонусов.

Поскольку один чек может быть представлен несколькими строками (например, из-за операций бонусной системы), сумма покупки *(summ_with_disc)* дублируется в этих строках. Использование функции *sum()* привело бы к повторному учету одной и той же суммы. Поэтому для получения фактической суммы чека используется агрегирующая функция *max()*.

В результате была сформирована витрина данных на уровне чека, где каждая строка соответствует одному чеку одного клиента.

Запрос 3. Определение даты отсчета.

Для корректного расчёта метрики *Recency* необходимо определить единую дату отсчёта – момент, относительно которого считается давность последней покупки. В рамках данного анализа в качестве такой даты используется дата последней покупки.

```
with asof as (
    select
        max(datetime) as asof_date
    from bonuscheques b
)
select *
from asof
```

Как итог, была получена единая точка отсчета, что используется для расчета Recency.

Запрос 4. Расчет базовых RFM – метрик.

Цель данного этапа – рассчитать для каждого клиента основные метрики RFM-анализа:

1. *Recency* – давность последней покупки клиента.
2. *Frequency* – количество покупок, совершенных клиентом.

3. *Monetary* – суммарная выручка, принесенная клиентом.

```
with checks as (
    select
        doc_id,
        card as customer_id,
        min(datetime) as dt,
        max(summ_with_disc) as amount
    from bonuscheques b
    group by doc_id, card
),
asof as (
    select max(dt) as asof_date
    from checks c
)
select
    customer_id,
    max(dt) as most_recent_purchase_date,
    count(*) as frequency,
    sum(amount) as monetary
from checks c
group by 1
```

В данном запросе рассчитываются базовые поведенческие метрики для каждого клиента:

- *max(dt)* – дата последней покупки клиента;
- *count(*)* – количество чеков у клиента;
- *sum(amount)* – суммарная выручка, принесенная клиентом

Таким образом формируется агрегированная таблица на уровне клиента, содержащая ключевые показатели покупательской активности.

Прежде чем переходить к этапу оценки и сегментации клиентов, необходимо провести предварительный анализ полученных метрик. В частности, следует проверить диапазоны значений и изучить распределения показателей *Recency*, *Frequency* и *Monetary*. Это позволяет выявить возможные аномалии в данных и определить корректные пороговые значения для последующей RFM-сегментации.

Анализ распределений метрик

На данном этапе целью анализа является переход от сырых клиентских метрик к RFM-сегментации, основанной на распределении данных. Для этого необходимо проанализировать диапазоны значений и основные статистические характеристики метрик.

Запрос 5. Анализ распределений метрики Recency.

В первую очередь были рассчитаны минимальное и максимальное значения, а также медиана *Recency*. Это позволяет проверить корректность диапазона значений и убедиться в отсутствии аномалий в данных.

```
select
    min(t.recency_days) as min_recency,
    max(t.recency_days) as max_recency,
    percentile_cont(0.5) within group (order by t.recency_days) as median_recency
from (
```

В результате получаем данные:

- **Минимальное значение** равно 0, что является ожидаемым результатом, поскольку в качестве даты отсчёта используется дата последней покупки в датасете.
- **Максимальное значение** находится в пределах одного года, что указывает на отсутствие очень старых единичных покупок.
- **Медианное значение** показывает, что половина клиентской базы совершала покупки относительно недавно – в пределах последних трёх месяцев.

Как следствие, распределение *Recency* реалистичное, метрика рассчитана корректно.

Запрос 6. Перцентили по *Recency* для выбора порогов для оценки.

Для определения пороговых значений сегментации были дополнительно рассчитаны квартильные перцентили распределения *Recency*. Использование перцентилей позволяет формировать сегменты на основе фактического распределения данных и избежать субъективного выбора границ.

```
select
    percentile_cont(0.25) within group (order by recency_days) as p25,
    percentile_cont(0.5)  within group (order by recency_days) as p50,
    percentile_cont(0.75) within group (order by recency_days) as p75
from recency_tbl;
```

В результате были получены следующие значения:

- p25 ≈ 29 дней
- p50 ≈ 87 дней
- p75 ≈ 182 дня

На основе полученных значений можно выделить четыре группы клиентов:

- **очень активные клиенты** – совершили покупку в течение последних 29 дней;

- **умеренно активные клиенты** – последняя покупка была в диапазоне от 29 до 87 дней;

- **«остывающие» клиенты** – последняя покупка была в диапазоне от 87 до 182 дней;

- **давно не покупавшие клиенты** – последняя покупка была более 182 дней назад.

Полученные пороговые значения используются на следующем этапе для формирования R-оценок и последующей RFM-сегментации клиентской базы.

Запрос 7. Проверка распределения *Frequency*

Метрика *Frequency* отражает количество покупок, совершённых клиентом за рассматриваемый период. Для клиентских данных данная метрика обычно характеризуется асимметричным распределением с длинным «хвостом»: большинство клиентов совершают небольшое количество покупок, тогда как небольшая группа клиентов демонстрирует значительно более высокую активность.

Для анализа распределения *Frequency* были рассчитаны минимальное и максимальное значения, а также квартильные перцентили.

```sql
select
    min(frequency) as min_frequency,
    max(frequency) as max_frequency,
    percentile_cont(0.25) within group (order by frequency) as p25,
    percentile_cont(0.5)  within group (order by frequency) as p50,
    percentile_cont(0.75) within group (order by frequency) as p75
from rfm_raw;
```

В результате анализа были получены следующие характеристики распределения:

- **Минимальное значение** равно 1, что ожидаемо, поскольку в выборку попадают только клиенты, совершившие хотя бы одну покупку.

- **Максимальное значение** составляет 217 покупок, что значительно выше среднего уровня и свидетельствует о наличии небольшой группы очень активных клиентов.

- **Перцентильные значения** показывают, что большинство клиентов совершают относительно небольшое количество покупок.

На основе рассчитанных перцентилей можно выделить ориентировочные пороги частоты покупок:

- **1 покупка** – клиенты с минимальной активностью;

- **2 покупки** – клиенты со средней частотой покупок;

- **5 и более покупок** – клиенты с высокой покупательской активностью.

Таким образом, распределение метрики *Frequency* подтверждает наличие типичного для клиентских данных длинного хвоста: небольшая доля клиентов совершает значительно больше покупок и, как правило, формирует существенную часть выручки. Полученные пороги используются на следующем этапе для формирования F-оценок в рамках RFM-сегментации.

Запрос 8. Анализ распределения *Monetary*

Метрика *Monetary* отражает совокупную ценность клиента и показывает суммарную выручку, принесённую клиентом за рассматриваемый период. Анализ данной метрики позволяет оценить распределение клиентской ценности и определить границы сегментов по уровню расходов.

Для анализа распределения *Monetary* были рассчитаны квартильные перцентили.

```sql
select
    percentile_cont(0.25) within group (order by monetary) as p25,
    percentile_cont(0.5)  within group (order by monetary) as p50,
    percentile_cont(0.75) within group (order by monetary) as p75
from rfm_raw;
```

В результате получены следующие значения:

- **p25 ≈ 731.25 руб.**

- **p50 ≈ 1586 руб.**

- **p75 ≈ 3727.25 руб.**

Полученные значения показывают, что половина клиентов приносит менее 1586 рублей суммарной выручки, тогда как верхний квартиль клиентов тратит более 3727 рублей. Это свидетельствует о значительной неоднородности клиентской базы с точки зрения уровня расходов.

Таким образом, распределение метрики *Monetary* позволяет выделить группы клиентов с низкой, средней и высокой ценностью. Полученные пороговые значения используются на следующем этапе для формирования M-оценок в рамках RFM-сегментации.

Запрос 9. Финальный расчет RFM

Цель данного этапа – сформировать итоговую RFM-витрину на уровне клиента и присвоить каждому клиенту дискретные оценки по метрикам **Recency**, **Frequency** и **Monetary**.

Для этого ранее рассчитанные метрики были преобразованы в категориальные оценки на основе пороговых значений, полученных при анализе распределений данных.

```
    select
    customer_id,
    (a.asof_date - r.most_recent_purchase_date) AS recency_days,
    case
        when (a.asof_date - r.most_recent_purchase_date) <= interval '29 days'  then 4
        when (a.asof_date - r.most_recent_purchase_date) <= interval '87 days'  then 3
        when (a.asof_date - r.most_recent_purchase_date) <= interval '182 days' then 2
        else 1
    end as r_score,
    r.frequency,
        case
            when r.frequency = 1 then 1
            when r.frequency between 2 and 5 then 2
            else 3
        end f_score,
    r.monetary,
    case
        when r.monetary <= 731 then 1
        when r.monetary <= 1586 then 2
        when r.monetary <= 3727.25 then 3
        else 4
    end as m_score,
    r.most_recent_purchase_date,
    a.asof_date
from rfm_raw r
cross join asof a
```

В данном запросе происходит преобразование непрерывных метрик в дискретные оценки:

- *Recency* – оценивается на основе давности последней покупки. Чем меньше времени прошло с момента последней покупки, тем выше оценка клиента.

- *Frequency* – отражает частоту покупок клиента. Более высокая частота покупок соответствует более высокой оценке.

- *Monetary* – показывает суммарную ценность клиента с точки зрения выручки.

Пороговые значения для присвоения оценок были определены на предыдущем этапе на основе анализа распределений и квартильных перцентилей. Такой подход позволяет сформировать сегментацию, отражающую фактическую структуру клиентской базы.

В результате выполнения данного запроса формируется итоговая RFM-таблица, в которой каждому клиенту присваиваются оценки R, F и M, отражающие его покупательскую активность и ценность для бизнеса.

Таким образом, каждый клиент получает дискретный RFM-профиль, который используется на следующем этапе для формирования клиентских сегментов.

Формирование RFM – сегментов

После расчёта RFM-оценок следующим этапом является формирование бизнес-ориентированных клиентских сегментов. Цель сегментации – выделить группы клиентов с различными моделями поведения, которые могут быть использованы для последующих маркетинговых и управленческих решений.

В рамках анализа были использованы классические паттерны RFM-сегментации:

- *«Champions»* – самые ценные и активные клиенты,
- *«Loyal»* – стабильные и регулярные покупатели,
- *«Potential Loyalists»* – клиенты с потенциалом роста,
- *«At Risk»* – клиенты с риском оттока,
- *«Lost»* – ушедшие клиенты,
- *«Other»* – нейтральная группа.

Формирование сегментов осуществлялось на основе комбинаций оценок **Recency**, **Frequency** и **Monetary**.

```
select
    customer_id,
    r_score,
    f_score,
    m_score,
    case
        when r_score = 4 and f_score = 3 and m_score = 4
            then 'Champions'
        when f_score = 3 and m_score >= 3 and r_score >= 3
            then 'Loyal'
        when r_score = 4 and f_score in (1, 2) and m_score in (2, 3)
            then 'Potential Loyalists'
        when r_score in (1, 2) and f_score >= 2 and m_score >= 2
            then 'At Risk'
        when r_score = 1 and f_score = 1 and m_score = 1
            then 'Lost'
        else 'Other'
    end as segment
from rfm_scores
```

Таким образом, каждому клиенту был присвоен сегмент на основе его RFM-профиля. Это позволяет перейти от отдельных метрик клиентского поведения к интерпретируемым группам клиентов, различающихся по уровню активности, ценности и вероятности оттока.

В результате, вся клиентская база была распределена по сегментам.

Для проверки корректности сегментации был проведён дополнительный анализ распределения клиентов и выручки между сегментами. Предполагается, что при корректной сегментации значительная часть выручки будет сосредоточена в сегментах «*Champions»* и «*Loyal»*, тогда как сегменты «*Other»* и «*Lost»* будут характеризоваться более низкой ценностью для бизнеса.

Бизнес рекомендации по RFM – сегментам.

Сформированная в рамках анализа RFM-сегментация позволяет выстроить более точную маркетинговую стратегию взаимодействия с клиентской базой. Использование сегментного подхода даёт возможность повысить LTV клиентов, снизить риск оттока наиболее ценных покупателей, а также оптимизировать маркетинговые расходы, концентрируя ресурсы на наиболее перспективных сегментах. Ниже будут представлены маркетинговые рекомендации к каждому из сегментов.

1. Сегмент «Champions»

Данный сегмент включает наиболее ценных клиентов компании. Они характеризуются высокой частотой покупок, высоким средним чеком и недавними покупками. Стратегической задачей при работе с данным сегментом является максимальное удержание клиентов и увеличение их пожизненной ценности.

Характерные черты:

- Высокая регулярность покупок
- Высокая частота покупок
- Высокий чек
- Стабильность поведения

Рекомендации: персонализированные предложения, программы повышенной лояльности (например, повышенный кэшбэк), сервисные преимущества (например, приоритетная доставка), избегать массовую рассылку скидок, уведомлений и пушей.

2. Сегмент «Loyal»

Данный сегмент включает клиентов со стабильным покупательским поведением и относительно высокой частотой покупок. Эти клиенты уже демонстрируют высокий уровень лояльности, однако их вклад в выручку может быть ниже, чем у сегмента «*Champions»*.

Основная стратегическая цель – удержание клиентов и постепенное повышение их ценности для бизнеса.

Характерные черты:

- Регулярность покупок
- Высокая частота покупок
- Средний/высокий чек
- Стабильность поведения

Рекомендации: персонализированные предложения на основе истории покупок, рекомендации сопутствующих товаров, стимулирование роста среднего чека.

Целью работы с данным сегментом является перевод части клиентов в сегмент *«Champions».*

3. **Сегмент «Potential Loyalists».**

Этот сегмент представляет собой одну из наиболее перспективных групп с точки зрения будущего роста клиентской базы. Клиенты уже проявили интерес к продукту, однако их покупательское поведение пока не является стабильным.

Стратегической задачей является формирование регулярной модели покупок и перевод клиентов в сегмент *«Loyal».*

Характерные черты:

- Покупки средней регулярности;
- Невысокая частота покупок;
- Средний чек;

Рекомендации: приветственные и стимулирующие предложения, бонусы за повторную покупку, небольшие скидки с ограниченным сроком действия.

Главная задача – закрепить привычку регулярных покупок

4. **Сегмент «At Risk»**

Клиенты данного сегмента ранее демонстрировали ценность для бизнеса, однако в настоящий момент их активность значительно снизилась. Это может свидетельствовать о высокой вероятности оттока.

Основная стратегическая задача – реактивация клиентов и предотвращение их ухода.

Характерные черты:

- давно не совершали покупок;
- ранее имели среднюю или высокую ценность
- частота покупок снизилась

Рекомендации: персональные предложения с ограниченным сроком, акции «вернись и получи бонус», важно избегать чрезмерного количества маркетинговых сообщений, чтобы не вызывать негативную реакцию клиентов.

5. **Сегмент «Lost»**

Этот сегмент включает клиентов, которые длительное время не совершали покупок и имеют низкую историческую ценность для бизнеса.

Основной стратегической целью является минимизация маркетинговых затрат при возможной точечной реактивации.

Характерные черты:

- давно не совершали покупок
- низкий суммарный чек
- низкая частота

Рекомендации: предлагать редкие, низкие по стоимости контакта, реактивационные кампании, крупный скидки, акции. Следует избегать частых рассылок

При работе с данным сегментом важно избегать частых коммуникаций и значительных маркетинговых затрат.

6. Сегмент «Other»

Сегмент *«Other»* объединяет клиентов с неоднородным поведением, которые не попали в ключевые категории RFM-сегментации. Как правило, данный сегмент характеризуется средней или низкой активностью.

Характерные черты:

- смешанное поведение;
- низкая частота
- средний чек

Рекомендации: информирование о текущих акциях и предложениях, использование недорогих каналов коммуникации, ограничение маркетинговых затрат.

Данный сегмент может рассматриваться как потенциальный источник роста, однако не должен быть приоритетным направлением маркетинговых инвестиций.